Informe Pràctica 1:

Identificador d’idioma

Processament del Llenguatge Humà

Irene Miralles
Berta Vidal

Índex

1. Introducció 3
2. Implementació 4
    2.1 Preprocessament del corpus 4
    2.2 Representació basada en n-grames 4
    2.3 Model probabilístic de llengua 5
    2.4 Procediment de classificació 5
3. Experimentació 7
    3.1 Experiment A: Impacte de l'ordre n 8
    3.2 Experiment B: Impacte de λ 10
    3.3 Experiment C: Accuracy per franja de longitud de frase 12
    3.4 Experiment D: Impacte dels símbols en els n-grames 14
4. Model final 17
Implementació 17
5. Conclusions 22

1. Introducció

En aquesta pràctica s'ha implementat un sistema d'identificació de llengua basat en un model probabilístic construït a partir de n-grames de caràcters. L'objectiu principal era desenvolupar un únic model capaç de discriminar entre sis idiomes, alemany, anglès, espanyol, francès, italià i neerlandès, a partir de patrons estadístics extrets dels textos d'entrenament.

Per a la construcció del model s'ha utilitzat el corpus Leipzig, format per textos periodístics en cadascun dels idiomes, dividit en conjunt d'entrenament i conjunt de prova. A partir del corpus d'entrenament s'han extret n-grames de caràcters i s'han estimat les probabilitats necessàries per al model amb suavitzat de Lidstone. Posteriorment, el sistema classifica nous textos calculant quina llengua és més probable segons els models entrenats.

A més de la implementació del sistema, la pràctica inclou una fase d'experimentació en què s'analitza l'impacte de diferents configuracions del model, com ara l'ordre dels n-grames, el paràmetre de suavitzat o el tractament dels símbols de puntuació. Aquesta anàlisi permet justificar la selecció del model final i comprendre millor els factors que influeixen en el rendiment del sistema.

2. Implementació

2.1 Preprocessament del corpus

El primer pas de la implementació consisteix en la lectura del corpus i l'aplicació d'un preprocessament homogeni per a tots els idiomes. Cada fitxer es carrega com una llista de frases de text, separant clarament els conjunts d'entrenament i de prova per a cadascun dels sis idiomes considerats. Sobre aquestes frases s'aplica una pipeline senzilla: eliminació dels dígits, conversió a minúscules, normalització d'espais en blanc i, en el cas del conjunt d'entrenament, concatenació de totes les frases amb un doble espai entre elles per obtenir un únic text continu per idioma. A partir d'aquest text preprocessat es calculen també estadístiques bàsiques, com el nombre total de caràcters de cada idioma, que permeten tenir una idea del volum efectiu de dades que alimenta els models de llengua.

Per al conjunt de prova s'utilitza una variant del preprocessament adaptada a frases individuals, que aplica la mateixa seqüència de transformacions però retornant un string per frase en lloc d'un corpus concatenat. Aquesta versió es fa servir posteriorment en la fase de classificació i en tots els experiments, garantint que el tractament del text de test és coherent amb el del text d'entrenament

2.2 Representació basada en n-grames

La representació interna del text es basa en n-grames de caràcters, amb un ordre n que es parametritza i s'ajusta en la fase d'experimentació. A partir del corpus preprocessat d'entrenament de cada idioma, s'extreuen n-grames de caràcters utilitzant les eines de nltk (BigramCollocationFinder, TrigramCollocationFinder, QuadgramCollocationFinder) i es compten les seves ocurrències mitjançant un Counter de Python. Per reduir soroll i controlar la mida del vocabulari, es fixa una freqüència mínima MINFREQ i només es mantenen els n-grames que superen aquest llindar. Aquest filtratge evita dedicar capacitat del model a n-grames extremadament rars, possibles errors tipogràfics o noms propis molt específics, que no generalitzen bé i podrien distorsionar les estimacions de probabilitat.

Sobre aquest conjunt de n-grames filtrats es calcula, per a cada idioma, el nombre total d'ocurrències N i la mida del vocabulari global B. En lloc de definir B per idioma, es pren la unió de tots els n-grames nets observats en qualsevol dels sis idiomes, de manera que tots els models comparteixen el mateix espai de possibles n-grames. Aquesta elecció garanteix

que el denominador del suavitzat és coherent entre idiomes: els n-grames exclusius d'una llengua penalitzen els altres models com a "no observats" però sobre un univers comú, fent la comparació entre puntuacions més justa i evitant que un idioma amb vocabulari més reduït tingui artificialment probabilitats més altes.

2.3 Model probabilístic de llengua

A partir dels comptatges n-grama de cada idioma es construeix un model de llengua de caràcters amb suavitzat de Lidstone, que permet assignar probabilitats estrictament positives a tots els n-grames possibles. La implementació pren com a entrada, per a cada idioma, el Counter d'n-grames filtrats, el total d'ocurrències N, la mida del vocabulari global B i un paràmetre de suavitzat λ, i en retorna un diccionari de log-probabilitats logp(ng) per a tots els n-grames observats conjuntament amb un valor logunseen per als n-grames que no apareixen al model. la tria òptima es determina empíricament a l'Experiment B.

Aquest esquema permet calcular de manera eficient la versemblança de nous textos, ja que un mateix mecanisme cobreix tant els n-grames observats com els no observats. Els models de tots els idiomes es guarden en una estructura models indexada pel codi d'idioma, de manera que resulta fàcil reconstruir-los amb diferents configuracions de n i λ durant l'experimentació.

2.4 Procediment de classificació

La classificació d'un text es basa en el principi de màxima versemblança. Donada una frase, es calcula la seva log-versemblança sota cada model de llengua i es retorna l'idioma que la maximitza. En primer lloc, la frase d'entrada es preprocessa i se'n generen els n-grames de caràcters corresponents. Per a cada idioma es calcula un score com la suma de les log-probabilitats dels seus n-grames, ponderades pel recompte d'aparicions dins la frase. Si un n-grama no es troba al model, s'utilitza el valor logunseen d'aquell idioma. La funció de classificació retorna l'idioma amb score global més alt, que es considera la llengua més probable.

Per facilitar l'anàlisi posterior, totes les prediccions sobre el conjunt de prova es desen en una llista all_results que, per a cada frase, recull l'idioma real, el text original, el text preprocessat, la predicció del sistema, un indicador d'encert i la longitud post-preprocessament. Aquesta estructura s'utilitza en les fases d'avaluació i en els experiments A–D tant per calcular mesures de rendiment agregades com per estudiar casos

concrets d'error i la influència de factors com la longitud de la frase o la presència de símbols de puntuació.

3. Experimentació

Amb l'objectiu d'analitzar el comportament del model probabilístic implementat, s'han dut a terme quatre experiments. El primer estudia l'impacte de l'ordre dels n-grames sobre el rendiment del sistema. El segon analitza la influència del paràmetre de suavitzat λ (Lidstone). El tercer examina com varia l'accuracy en funció de la longitud del text. Finalment, el quart experiment avalua l'impacte dels símbols i de la puntuació en el model. Aquests experiments permeten comprendre quins factors influeixen realment en la capacitat de discriminació del sistema.

Cal esmentar que abans de descriure els experiments concrets, s'ha definit una funció general (run_experiment) que encapsula tot el pipeline d'entrenament i avaluació del model per a uns paràmetres donats (ordre n i valor de λ). Aquesta funció construeix els models probabilístics a partir del corpus d'entrenament preprocessat, calcula el vocabulari global (B) i el nombre total d'n-grames per llengua (N), aplica el suavitzat corresponent i classifica les frases del conjunt de prova ja preprocessades. Finalment, retorna l'accuracy obtinguda i les prediccions realitzades. En l'experiment D no es fa ús d'aquesta funció.

Aquesta abstracció permet executar fàcilment diferents configuracions del model modificant únicament els paràmetres, mantenint constant la resta del procés experimental.

3.1 Experiment A: Impacte de l'ordre n

Implementació

En aquest experiment s'ha estudiat l'impacte de l'ordre dels n-grames en el rendiment del model, mantenint fix el paràmetre de suavitzat λ = 0.5.

S'han provat tres valors d'n: 2, 3 i 4. Per a cadascun d'aquests valors, s'ha executat la funció run_experiment, que construeix el model corresponent i l'avalua sobre el conjunt de prova.

Els resultats obtinguts (accuracy i nombre d'errors) s'han emmagatzemat per poder comparar les diferents configuracions. Finalment, s'ha generat una representació gràfica que mostra l'evolució de l'accuracy en funció de l'ordre n, facilitant la visualització de l'impacte d'aquest paràmetre.

D'aquesta manera, l'única variable modificada en l'experiment és l'ordre dels n-grames, mantenint constant la resta de paràmetres i el preprocessament.

Anàlisi dels resultats

En realitzar l'experiment s'han obtingut els següents resultats.

Ordre n	Accuracy	Errors
2	0.9945	332
3	0.9988	72
4	0.9996	22

Com podem observar a la taula, l'accuracy augmenta clarament a mesura que incrementa l'ordre dels n-grames. Amb n = 2 s'obté una accuracy del 99.45% (332 errors), mentre que amb n = 3 el rendiment millora significativament fins al 99.88% (72 errors). Finalment, amb n = 4 s'assoleix un 99.96% d'accuracy, reduint els errors a només 22 casos.

Aquest increment també es pot apreciar visualment a la Figura 1, que mostra l'evolució de l'accuracy en funció de l'ordre n.

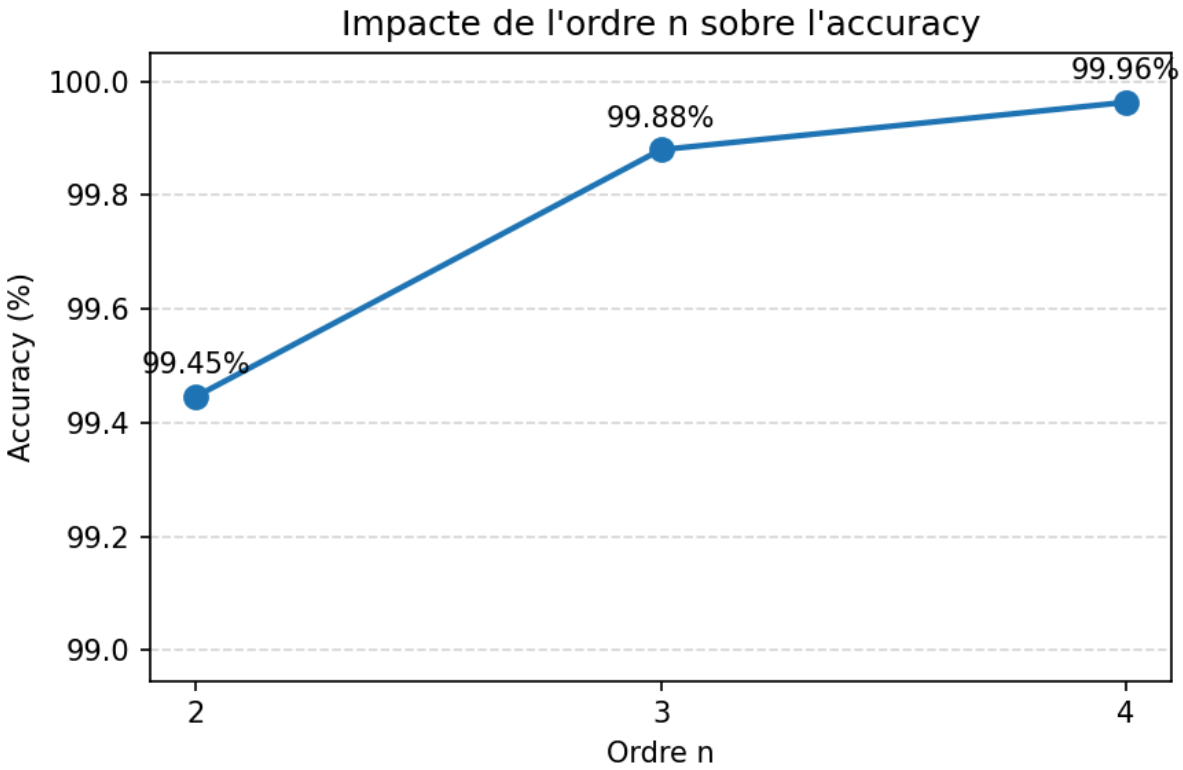

Figura 1: Evolució de l'accuracy segons l'ordre n

Com podem observar a la figura, la millora entre n = 2 i n = 3 és especialment pronunciada, mentre que el pas de n = 3 a n = 4 comporta un increment més modest. Això indica que els trigrames ja capturen una part molt significativa dels patrons característics de cada llengua, i que l'ús de n = 4 aporta una millora menor.

Podem concloure que l'augment de n permet considerar contextos més llargs i específics, fet que incrementa la capacitat discriminativa del model. Els bigrames capturen informació més limitada, mentre que els trigrames i n-grames d'ordre 4 incorporen seqüències més distintives pròpies de cada idioma. No obstant això, a mesura que n creix, el guany es redueix, ja que el model ja disposa de prou informació per discriminar adequadament entre llengües.

En conjunt, els resultats mostren que l'ordre n té un impacte clar en el rendiment, especialment en el pas de bigrames a trigrames, que suposa la millora més significativa.

3.2 Experiment B: Impacte de λ

Implementació

En aquest experiment s'ha analitzat l'impacte del paràmetre de suavitzat λ (suavitzat de Lidstone) en el rendiment del model, mantenint fix l'ordre dels n-grames en n = 3, el recomanat per l'enunciat. L'objectiu és estudiar com varia l'accuracy del sistema en funció del grau de suavitzat aplicat a les probabilitats estimades.

S'han considerat diversos valors de λ compresos entre 0.10 i 1.00, generats de manera uniforme dins aquest interval. Per a cadascun d'aquests valors s'ha executat la funció run_experiment, mantenint constants el preprocessament, el conjunt d'entrenament i el conjunt de prova. D'aquesta manera, l'única variable modificada en aquest experiment és el valor del paràmetre de suavitzat.

De nou, per cada configuració s'han registrat l'accuracy i el nombre d'errors obtinguts en el conjunt de prova, amb l'objectiu de comparar el comportament del model sota diferents graus de regularització.

Així, aquest experiment permet avaluar la sensibilitat del model respecte al paràmetre de suavitzat, mantenint constant la resta d'elements del pipeline.

Anàlisi dels resultats

En realitzar l'experiment s'han obtingut els següents resultats.

λ	Accuracy	Errors
0.10	0.9987	79
0.25	0.9987	76
0.40	0.9988	74
0.55	0.9988	72
0.70	0.9988	71
0.85	0.9988	72
1.00	0.9988	71

Com podem observar a la taula, l'accuracy del model es manté molt estable al llarg de tots els valors de λ considerats. Els valors accuracy oscil·len entre 0.9987 i 0.9988, amb una variació pràcticament negligible. En termes de nombre d'errors, les diferències també són molt reduïdes, situant-se entre 71 i 79 errors.

Aquest comportament es pot apreciar visualment a la Figura 2, que mostra l'evolució de l'exactitud en funció del valor de λ.

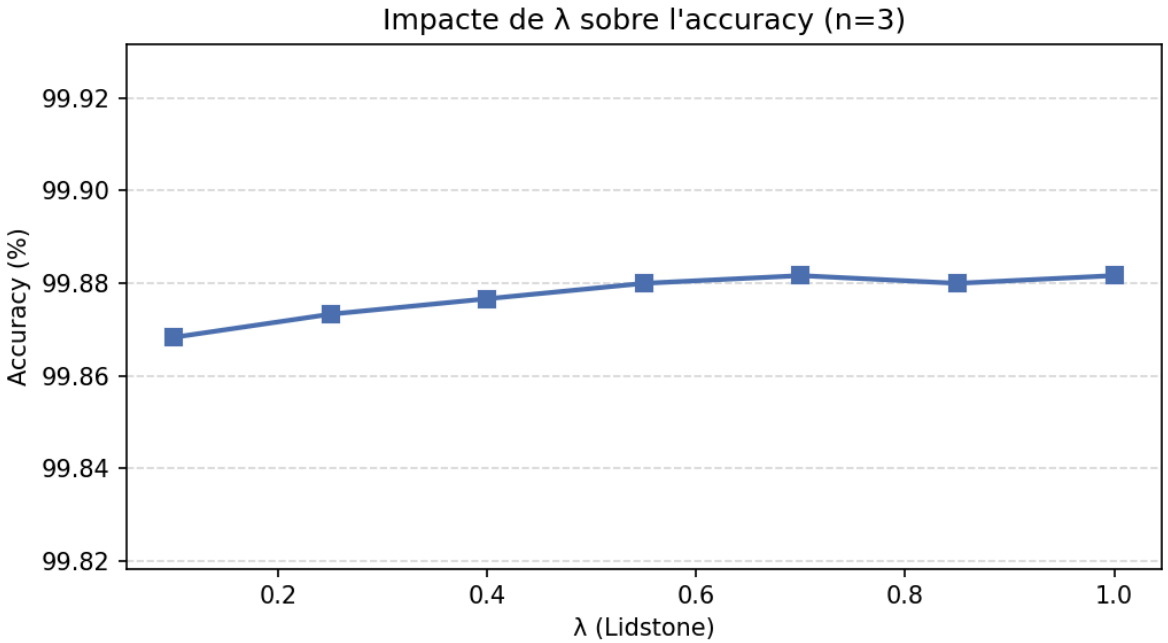

Figura 2: Evolució de l'accuracy segons λ

Com podem observar a la figura, la corba és pràcticament plana, amb una lleugera millora a mesura que λ augmenta des de 0.10 fins aproximadament 0.70, i una estabilització posterior. No s'identifica cap variació brusca ni cap punt òptim clarament diferenciat dins l'interval analitzat.

Aquests resultats indiquen que el model és poc sensible al valor concret del paràmetre de suavitzat dins del rang considerat. El suavitzat de Lidstone permet evitar probabilitats nul·les, però un cop garantit aquest efecte, petites variacions en λ no alteren de manera significativa el rendiment global del sistema.

En conjunt, es pot concloure que, per n = 3 i amb el corpus utilitzat, el model presenta una elevada robustesa respecte al paràmetre de suavitzat, i que la seva influència en l'exactitud és molt menor que la de l'ordre dels n-grames observada a l'Experiment A.

3.3 Experiment C: Accuracy per franja de longitud de frase

Implementació

En aquest experiment s'ha analitzat com afecta la longitud del text al rendiment del sistema d'identificació de llengua. A diferència dels experiments anteriors, en aquest cas no es modifiquen paràmetres del model, sinó que es segmenta el conjunt de prova en funció de la longitud de cada frase i s'avalua el comportament del classificador en cada franja.

S'han definit tres intervals de longitud (en nombre de caràcters): frases curtes (< 50), mitjanes (50–120) i llargues (> 120). Cada frase s'ha assignat a la seva franja corresponent utilitzant el camp de longitud (len).

Per a cada subconjunt s'ha calculat l'accuracy i el nombre d'errors. D'aquesta manera, l'experiment permet avaluar de forma directa la relació entre la longitud del text i el rendiment del classificador, mantenint constants el model, el preprocessament i els paràmetres ($n = 3$ i $\lambda = 0.5$).

Anàlisi dels resultats

En realitzar l'experiment s'han obtingut els següents resultats.

Franja	Frases	Errors	Accuracy
<50	6026	36	99.40%
50-120	26985	30	99.89%
>120	26966	6	99.98%

Com podem observar a la taula, l'accuracy del model augmenta a mesura que creix la longitud de les frases. En el cas de les frases curtes (< 50 caràcters), l'accuracy és del 99.40%, amb 36 errors sobre 6.026 frases. Per a les frases de longitud mitjana (50–120), el rendiment millora fins al 99.89%, amb 30 errors sobre 26.985 casos. Finalment, en les frases llargues (> 120), s'assoleix un accuracy del 99.98%, amb només 6 errors sobre 26.966 frases.

Aquest comportament es pot apreciar visualment a la Figura 3, que representa l'exactitud per franja de longitud.

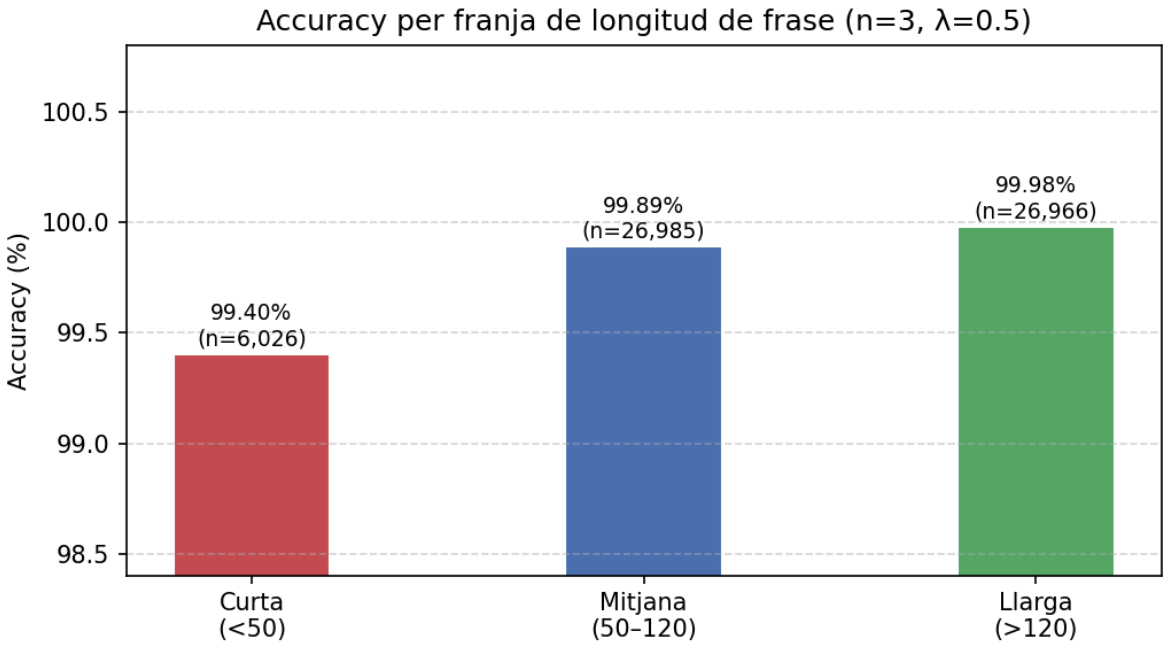

Figura 3: Accuracy segons la longitud de les frases

Com podem observar a la figura, existeix una tendència clarament creixent: les frases més llargues obtenen sistemàticament millors resultats que les més curtes. La diferència entre frases curtes i mitjanes és especialment notable, mentre que el pas de frases mitjanes a llargues comporta una millora addicional però més moderada.

Aquests resultats són coherents amb la naturalesa del model basat en n-grames. A mesura que la longitud del text augmenta, el classificador disposa de més seqüències de caràcters sobre les quals estimar probabilitats, fet que incrementa l'evidència disponible per discriminar entre llengües. En textos molt curts, en canvi, la quantitat d'informació és més limitada, i petites coincidències aleatòries poden tenir un impacte proporcionalment més gran en la decisió final.

En conjunt, es pot concloure que la longitud del text és un factor rellevant en el rendiment del sistema: el model mostra una major robustesa a mesura que augmenta la longitud, confirmant que el volum d'informació condiciona directament la capacitat de classificació.

3.4 Experiment D: Impacte dels símbols en els n-grames

Implementació

En aquest experiment s'ha analitzat fins a quin punt la presència de símbols (signes de puntuació, caràcters no alfabètics, etc.) dins dels n-grammes contribueix al rendiment del model. A diferència dels experiments anteriors, aquí no es modifica únicament un hiperparàmetre, sinó que es comparen tres configuracions estructuralment diferents del model, fet que requereix una implementació específica.

En primer lloc, s'ha definit una funció *is_symbol_only*, que determina si un n-grama està format exclusivament per caràcters que no són ni lletres ni dígits, utilitzant les categories Unicode per discriminar-los. Això permet identificar trigrames compostos únicament per símbols.

A partir d'aquesta definició, s'han considerat tres escenaris:

1. **Original (puntuació inclosa):**

   Model original, entrenat amb el preprocessament estàndard i amb tots els n-grames disponibles.

2. **Sense trigrames purs de símbols:**

   Es construeixen nous comptadors eliminant únicament els n-grames formats exclusivament per símbols, mantenint la resta del preprocessament intacte. Posteriorment, es recalcula N, B i es reconstrueix el model amb els mateixos hiperparàmetres.

3. **Sense cap puntuació (preprocessament):**

   Es redefineix el preprocessament per eliminar completament els símbols. Seguidament es recalculen els paràmetres i es reconstrueix el model de nou.

Per a cadascun dels tres casos s'han calculat l'accuracy i el nombre total d'errors sobre el mateix conjunt de prova.

Anàlisi dels resultats

En realitzar l'experiment s'han obtingut els següents resultats.

Condició	Accuracy	Errors
Original (puntuació inclosa)	0.9988	72
Sense trigrames purs de símbols	0.9987	76
Sense cap puntuació	0.9984	96

Com podem observar a la taula, el model baseline (amb puntuació inclosa) obté una accuracy de 0.9988 (99.88%) amb 72 errors. Quan s'eliminen únicament els trigrammes formats exclusivament per símbols, el rendiment disminueix lleugerament fins a 0.9987 (76 errors). Finalment, quan s'elimina completament la puntuació en el preprocessament, l'accuracy baixa fins a 0.9984, amb un increment notable dels errors (96).

Aquests resultats es poden visualitzar de manera més clara a la Figura 4, que compara gràficament les tres configuracions.

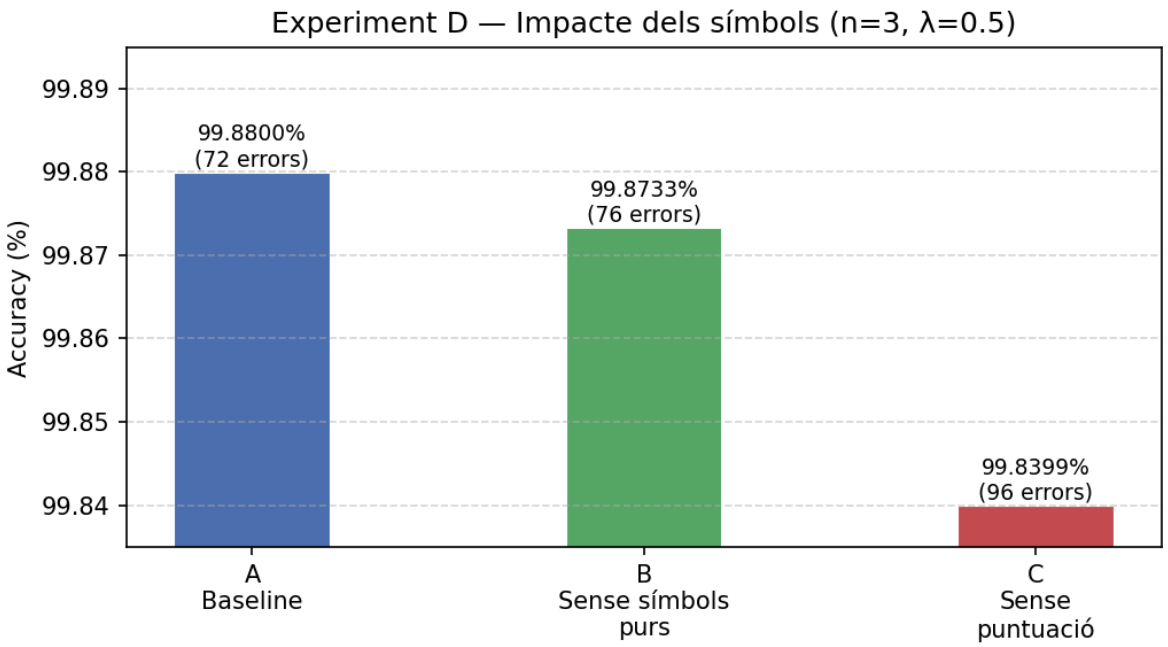

Figura 4: Accuracy segons el tractament dels símbols

Com podem observar a la figura, les diferències en accuracy són petites en termes absoluts, però consistents. El model amb puntuació inclosa és el que obté millor rendiment. L'eliminació exclusiva dels trigrames purs de símbols comporta una lleu degradació, mentre que la supressió completa de la puntuació produeix una disminució més clara del rendiment.

Per entendre millor aquest comportament, la següent taula mostra el nombre total de trigrames formats exclusivament per símbols per idioma, així com el percentatge que representen respecte del total de trigrammes.

Idioma	Nombre de trigrames purs de símbols	% del total
Alemany	45,656	1.35%
Anglès	51,260	1.42%
Espanyol	49,802	1.26%
Francès	49,363	1.34%
Italià	52,861	1.39%
Neerlandès	43,995	1.39%

Com podem observar, els trigrammes purament simbòlics representen aproximadament entre l'1.26% i l'1.42% del total, segons l'idioma. Es tracta, per tant, d'una fracció relativament petita del vocabulari de n-grames. Tot i això, la seva eliminació té un impacte mesurable en el rendiment.

Aquest resultat suggereix que, malgrat ser quantitativament minoritaris, aquests trigrammes poden aportar informació discriminativa útil. La puntuació i determinades combinacions de símbols poden reflectir patrons que varien lleugerament entre llengües. En eliminar-los completament, es redueix la quantitat total d'evidència disponible per al model.

Cal destacar que la diferència entre el baseline i l'eliminació exclusiva de trigrammes purs és molt reduïda, mentre que l'eliminació total de la puntuació genera una degradació més clara. Això indica que el principal impacte no prové només dels n-grammes formats exclusivament per símbols, sinó del conjunt de patrons que combinen lletres i signes de puntuació dins dels trigrammes.

En conjunt, es pot concloure que la presència de símbols no és un factor dominant en el rendiment global del sistema, però sí contribueix de manera positiva. El model es beneficia lleugerament de mantenir la puntuació, fet que suggereix que aquests elements formen part de la representació estadística útil per a la tasca d'identificació de llengua.

4. Model final

Implementació

El model final s'ha entrenat utilitzant els paràmetres que han mostrat millor comportament experimental:

- Ordre dels n-grames: n=3
- Suavitzat (Lidstone): λ=0.7
- Mantenint puntuació i símbols

Tot i que a l'Experiment A l'ordre n=4 obtenia una accuracy lleugerament superior, s'ha optat per n=3, ja que l'enunciat recomanava explícitament aquest valor i la diferència empírica observada respecte a n=4 era molt petita.

Anàlisi global del model

El model final (n = 3, λ = 0.7, min_freq = 5) obté una accuracy global del 99.88%, amb 71 errors sobre un total de 59.977 exemples.

A continuació es mostra la taula amb les mètriques detallades per idioma (precision, recall i F1-score).

Idioma	Precision	Recall	F1-score
Alemany	0.9992	0.9991	0.9991
Anglès	0.9974	0.9995	0.9984
Espanyol	0.9992	0.9991	0.9991
Francès	0.9993	0.9989	0.9991
Italià	0.9990	0.9986	0.9988
Neerlandès	0.9977	0.9977	0.9982

Podem observar que tots els idiomes presenten valors de precision, recall i F1-score superiors a 0.998. Això ens demostra que les diferències entre idiomes són mínimes a l'hora d'executar el classificador.

La matriu de confusió confirma visualment el bon comportament del model.

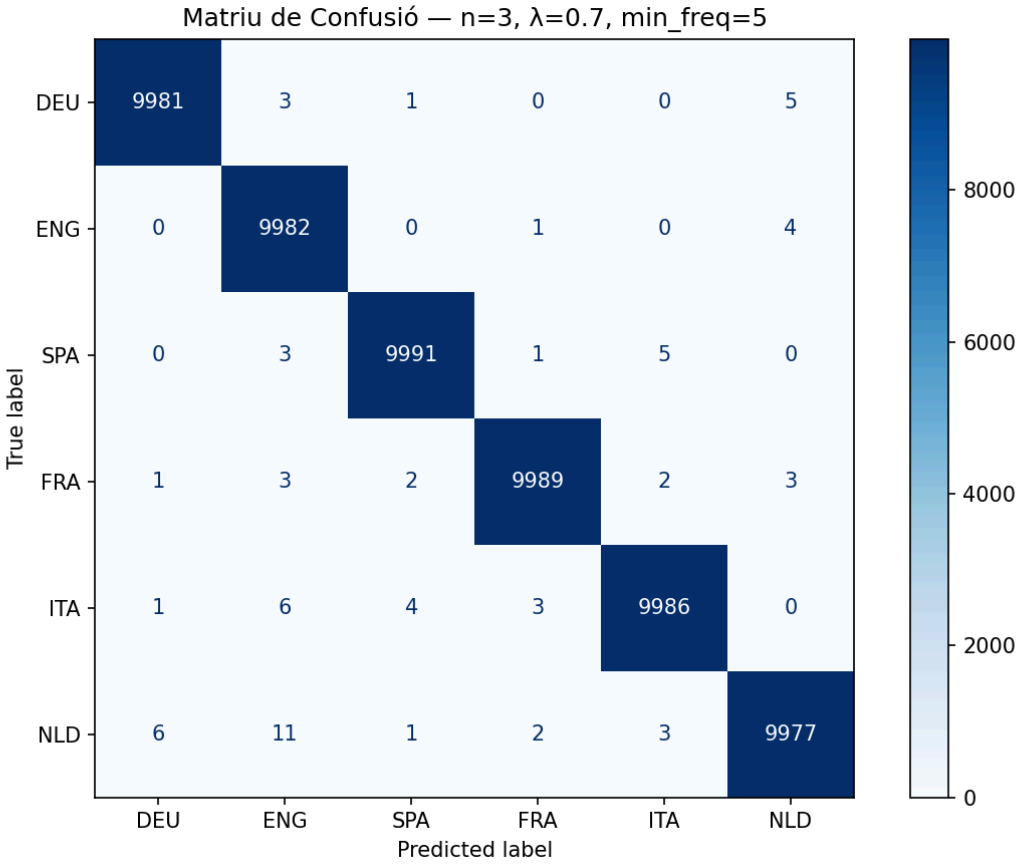

Figura 5: Matriu de confusió del model final

Podem observar que pràcticament totes les mostres es concentren a la diagonal. Les confusions observades són puntuals i de baixa magnitud, això indica que el model discrimina correctament entre idiomes en gairebé tots els casos.

En conjunt, l'anàlisi global mostra que el model presenta un rendiment molt alt, amb un comportament homogeni entre tots els idiomes. No s'observen biaixos significatius ni cap llengua clarament perjudicada.

Anàlisi dels errors

Tot i que el model presenta una accuracy molt elevada (71 errors sobre 59.977 exemples, 0,1184%), és rellevant analitzar qualitativament i quantitativament aquests errors per entendre'n el patró.

A partir de la matriu de confusi (Figura X) podem identificar quines llengües es confonen amb més freqüència. En particular, els 10 principals parells de confusió (veritat → predicció) són:

- NLD → ENG (11 errors)
- ITA → ENG (6 errors)
- NLD → DEU (6 errors)
- DEU → NLD (5 errors)
- SPA → ITA (5 errors)
- ENG → NLD (4 errors)
- ITA → SPA (4 errors)
- DEU → ENG (3 errors)
- SPA → ENG (3 errors)
- FRA → NLD (3 errors)

S'observa que les confusions més freqüents es produeixen entre idiomes tipològicament o geogràficament propers: neerlandès–anglès i neerlandès–alemany dins l'àmbit germànic, i espanyol–italià dins l'àmbit romànic. No apareixen confusions massives ni sistemàtiques cap a una sola llengua, fet que reforça la idea d'un model equilibrat.

A continuació mencionarem alguns exemples concrets. Cal esmentar que la llengua amb més errors és el neerlandès, amb un total de 23 errors.

Presentem dos exemples representatius per idioma:

- **Alemany (9 errors en total)**
    - "Der Stoffbeutel war leer." Predit com Neerlandès. Podem observar que es tracta d'una frase curta i estructuralment molt similar al neerlandès.
    - "Ist das Land bald insolvent?" Predit com Anglès. Podem observar presència de lèxic internacional ("insolvent") i una estructura interrogativa simple.

  Anglès (5 errors en total)

    - "It feels strange." Predit com Neerlandès. Podem observar que es tracta d'una frase molt curta amb trigrames comuns en llengües germàniques.
    - "Internet trouble." Predit com francès. Podem observar una absència de marques morfològiques clares; lèxic internacional.

- **Espanyol (9 errors en total)**

    - “Ahora, me da la risa al recordarlo.” Predit com Italià. L’Espanyol i l’Italià tenen similitud sintàctica i lèxica.
    - “Explique brevemente por qué.” Predit com Francès. Podem observar presència d’accents i estructura formal que pot solapar-se amb patrons francesos.

- **Francès (11 errors en total)**
    - “On a su en profiter.” Predit com Espanyol. Podem observar una estructura breu.
    - “Encore une star addict de Twiiter!” Predit com Anglès. Podem observar presència de lèxic anglès (“star”, “addict”).

- **Italià (14 errors en total)**
    - “Champions o Europa League?” Predit com Francès. Podem observar lèxic esportiu internacional.
    - “Wall Street in deciso rosso.” Predit com Anglès. Podem observar la presència de nom propi anglès (Wall Street).

- **Neerlandès (23 errors)**
    - “De term werd bedacht door Anthony Downs in An Economic Theory of Democracy uit 1957.” Predit com Anglès. Podem observar gran quantitat de segments en anglès dins la frase.
    - “Lüttchendorf telt 654 inwoners.” Predit com Alemany. Podem observar resència de diacrítics i topònims d’aparença alemanya, ambdues són llengües germàniques.

En general, els errors es concentren enEn general, els errors es concentren en: frases molt curtes, presència de noms propis o fragments en altres idiomes, lèxic internacional (marques, esports, institucions), alta similitud estructural entre llengües germanes.

També hem analitzat els 10 trigrames més discriminatius per idiomes.

Alemany	‘übe’	‘ür ‘	‘zu ‘	‘ üb’	‘ fü’	‘für’	‘ ih’	‘ihr’	‘tzt’	‘nnt’
Anglès	‘,” ‘	‘n’t’	‘tly’	‘whe’	‘nly’	‘’t ‘	‘who’	‘u.s’	‘wou’	‘yea’
Espanyol	‘ión’	‘ció’	‘ón ‘	‘más’	‘ má’	‘ía ‘	‘año’	‘ y ‘	‘ría’	‘ió ‘
Francès	‘ à ‘	‘e à’	‘été’	‘s à’	‘t à’	‘qu’’	‘eux’	‘ès ‘	‘ ét’	‘prè’

Italià	‘ è ‘	‘tà ‘	‘ità’	‘rà ‘	‘più’	‘iù ‘	‘ll’’	‘è s’	‘uov’	‘o è’
Neerlandès	‘ij ‘	‘voo’	‘ijn’	‘zij’	‘jn ‘	‘ijk’	‘jke’	‘lij’	‘jk ‘	‘ oo’

Podem observar alguns patrons distintius com, per exemple, la presència d’accents, dièresis, terminacions o combinacions vocàliques característiques.

Finalment, també hem calculat el solapament de vocabulari entre parells d’idiomes utilitzant el coeficient de Jaccard sobre els conjunts de trigrames. Aquest coeficient mesura la similitud entre dos conjunts com la proporció entre el nombre d’elements compartits (intersecció) i el nombre total d’elements diferents presents en ambdós conjunts (unió). Els resultats mostren que alguns idiomes comparteixen una proporció elevada de trigrames (especialment anglès i neerlandès, així com alemany i neerlandès), cosa que explica en part les confusions observades en l’avaluació del model. A més, l’anàlisi dels trigrames més ambigus entre alemany i neerlandès revela seqüències molt comunes en ambdós idiomes (com en, de o er), que tenen poca capacitat discriminativa. En conjunt, aquest resultat confirma que els errors del model es produeixen principalment entre idiomes amb patrons ortogràfics similars

5. Conclusions

Conclusions generals

Cal tenir en compte que el corpus utilitzat presenta una alta similitud entre el conjunt d'entrenament i el conjunt de prova. Això facilita la tasca de classificació i contribueix a obtenir resultats molt elevats. Per tant, tot i que els resultats obtinguts són bons, una avaluació més correcte requeriria utilitzar un conjunt de prova completament independent.

Gràcies a l'anàlisi realitzada hem pogut extreure diverses conclusions sobre el comportament del model:

- L'ordre dels n-grames és el factor que té més impacte en el rendiment del sistema. L'augment de n permet capturar contextos més llargs i específics, fet que millora la capacitat discriminativa del model. La millora més significativa es produeix en passar de bigrames a trigrames.

- El paràmetre de suavitzat λ té una influència molt limitada en el rendiment dins del rang analitzat. Un cop s'eviten probabilitats nul·les, petites variacions en aquest valor no modifiquen de manera significativa l'accuracy del sistema.

- La longitud del text és un factor clau en la classificació. Les frases més llargues proporcionen més evidència i permeten al model estimar millor les probabilitats dels n-grames, cosa que es tradueix en una major precisió.

- La puntuació i els símbols poden aportar informació útil. Tot i que els n-grames formats exclusivament per símbols representen una proporció petita del total, la seva eliminació redueix lleugerament el rendiment del model, cosa que indica que alguns patrons que combinen lletres i puntuació poden contribuir a la discriminació entre idiomes.

- El model final obté un rendiment elevat i homogeni entre idiomes. Les mètriques mostren que no hi ha llengües clarament perjudicades i que les confusions observades són molt limitades.

- Els errors es produeixen principalment entre idiomes amb similitud lingüística o amb patrons ortogràfics compartits. Això es reflecteix tant en les confusions observades a

la matriu de confusió com en el solapament de vocabulari entre idiomes, especialment entre llengües germàniques o romàniques.

Possibles millores

Tot i que el model presenta un rendiment molt alt, encara existeixen diverses línies de millora que es podrien explorar en futurs treballs:

- Realitzar una avaluació amb un corpus independent. Com s'ha mencionat anteriorment, seria convenient validar el model amb textos provinents d'una font diferent per comprovar fins a quin punt el sistema generalitza fora del domini del corpus utilitzat.

- Combinació de diferents ordres d'n-grames. En lloc d'utilitzar un únic valor de n, es podria combinar informació de diversos ordres (per exemple, bigrames, trigrames i quadrigrames) per capturar patrons de diferents longituds.

- Exploració d'altres tècniques de suavitzat. Es podria analitzar el comportament del model amb altres mètodes de suavitzat més avançats utilitzats en models de llengua.

- Ampliació del conjunt d'idiomes o de dominis textuals. Incorporar més llengües o textos de diferents gèneres (per exemple, textos més informals o de xarxes socials) permetria analitzar la robustesa del sistema en escenaris més variats.